Caja Negra de Obra

Cómo diseñamos y construimos un sistema que lee el cuaderno de obra digital para auditar consultas y anticipar atrasos en las obras públicas de Arequipa

Gestión de Sistemas y Tecnologías de Información · Escuela de Ingeniería de Sistemas · UNSA · noviembre 2026

El problema en una frase

Las señales de que una obra se está trabando quedan escritas en el cuaderno de obra, pero se leen tarde: cuando el atraso ya ocurrió.

Cuando un avión cae se lee su caja negra. En una obra pública la caja negra es el cuaderno de obra: nosotros lo leemos mientras la obra sigue viva.

Por qué vale la pena: el problema existe y se puede medir

126

obras paralizadas en Arequipa al 31-03-2026 (Contraloría, Tabla 3)

8 383

millones de soles de costo actualizado: 3.er departamento del país

37 %

de 6 472 consultas del residente tiene respuesta en el cuaderno

19 %

de las respuestas registradas llegó fuera del plazo legal

Por qué es un problema de sistemas de información: en Arequipa hay 104 299 asientos en 629 cuadernos. Nadie puede leerlos cada mes, y los datos abiertos no dicen qué respuesta contesta qué consulta. El dato existe, pero no se convierte en información.

Fuentes: Contraloría, Informe N.° 001-2026-CG/SESNC (corte 31-03-2026); cálculo propio sobre datos abiertos del OECE, junio 2024 a agosto 2026.

Causas y efectos que guían el diseño



Cómo lo pensamos como equipo

Del problema a las decisiones: proceso de trabajo, requerimientos y arquitectura

Nuestro proceso y las reglas que no se negocian

1 — Entender

Árbol de problemas, norma (RLCE y RLGCP) y cifras oficiales

2 — Elegir datos

Fuentes abiertas, oficiales y fechadas; linaje SHA-256

3 — Diseñar

Requerimientos, arquitectura y decisiones registradas

4 — Construir

Un componente a la vez, cada uno con su métrica

5 — Medir

Prueba temporal, comparadores e intervalos

6 — Publicar

Web estática, informe y código abierto

Cero datos inventados

Toda cifra sale de un JSON generado por un script versionado.

Sin ver el futuro

Cada indicador del mes T usa solo información con fecha ≤ T.

Decidir con validación

Umbrales, calibración y modelo se eligen antes de mirar la prueba.

Explicar cada alerta

Probabilidad, razones y el asiento original como prueba.

Qué debe cumplir: tres preguntas y cinco atributos de calidad

R1 ### ¿Se va a atrasar?

Probabilidad de atraso legal a 60 días, su nivel, su evolución y las razones.

R2 ### ¿Quién la está trabando?

Cada consulta con su plazo legal (5 o 21 días), su estado y el responsable.

R3 ### ¿Qué está pasando?

Plazo frente a avance, dinero, historial y hechos formales del cuaderno.

Atributo	Requisito	Cómo se cumple (medido)
Privacidad	Ningún dato personal publicado	Anonimización + prueba automática
Trazabilidad	Saber qué modelo y datos generaron cada cifra	meta.json: esquema, huella del modelo, commit
Rendimiento	Lista visible en menos de 2 s	566 ms (mediana de 5 cargas)
Accesibilidad	WCAG 2 AA, teclado y móvil	axe-core: 0 violaciones en las 3 vistas
Costo	Operar sin licencias ni servidores	Datos abiertos + GitHub Pages

Decisiones de arquitectura y lo que aceptamos a cambio

Decisión	Alternativa descartada	Por qué	Costo aceptado
Proceso por lotes mensual + web estática	API y base de datos en línea	El OECE publica cada mes; costo cero y casi sin superficie de ataque	No hay consultas en tiempo real
Cuaderno de obra como fuente central	Solo INFOBRAS	Es diario, oficial, fechado y obligatorio	No cubre administración directa
LightGBM + TreeSHAP	Red neuronal profunda	Datos tabulares; explicable por obra; corre en CPU	Techo de exactitud posible
Sentence-BERT local	Modelo de lenguaje externo	Gratis, medible y no envía datos a terceros	Menor comprensión del texto
Entrenar con el país, evaluar en Arequipa	Solo Arequipa	Arequipa tiene pocos atrasos (203 obras-mes)	Diferencias regionales
Contrato de datos versionado	Web que lee lo que encuentre	La web rechaza datos de otro esquema	Regenerar todo en cada corte

Arquitectura: cinco capas desacopladas por archivos



Por qué así

- Cada capa solo lee archivos de la anterior: se puede probar, rehacer o cambiar sin tocar las demás.
- Lo pesado (IA) corre una vez al mes; la web solo lee JSON pequeños.
- Sin servidor ni base de datos en línea: no hay credenciales que proteger ni costo de operación.
- Un catálogo único de indicadores alimenta el modelo, la web y el informe.

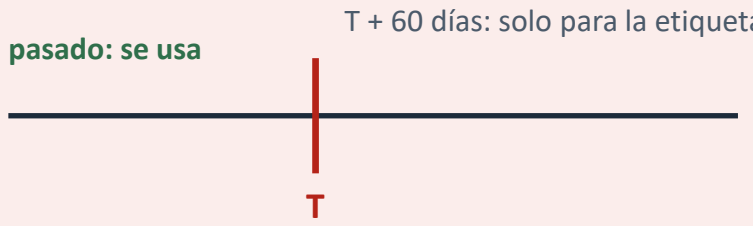
Cómo construimos los datos y la IA

Fuentes y corte temporal, pipeline reproducible, emparejador, motor de plazos, indicadores y modelo

Datos: de dónde sale cada cosa y la regla del tiempo

Fuente	Qué tomamos	Cómo se verifica
OECE · cuaderno digital	2 732 592 asientos del país (jun-2024 a ago-2026)	URL y SHA-256 por archivo
MEF · SIAF y Banco de Inversiones	Devengado mensual, monto viable, problemas	Solo meses ≤ T
INFOBRAS	Plazo y fechas originales del contrato	Datos fijos; nunca el avance actual
SEACE / CONOSCE	Monto contratado	Cruce por obra
Contraloría	Contexto: obras paralizadas	PDF oficial leído tabla por tabla

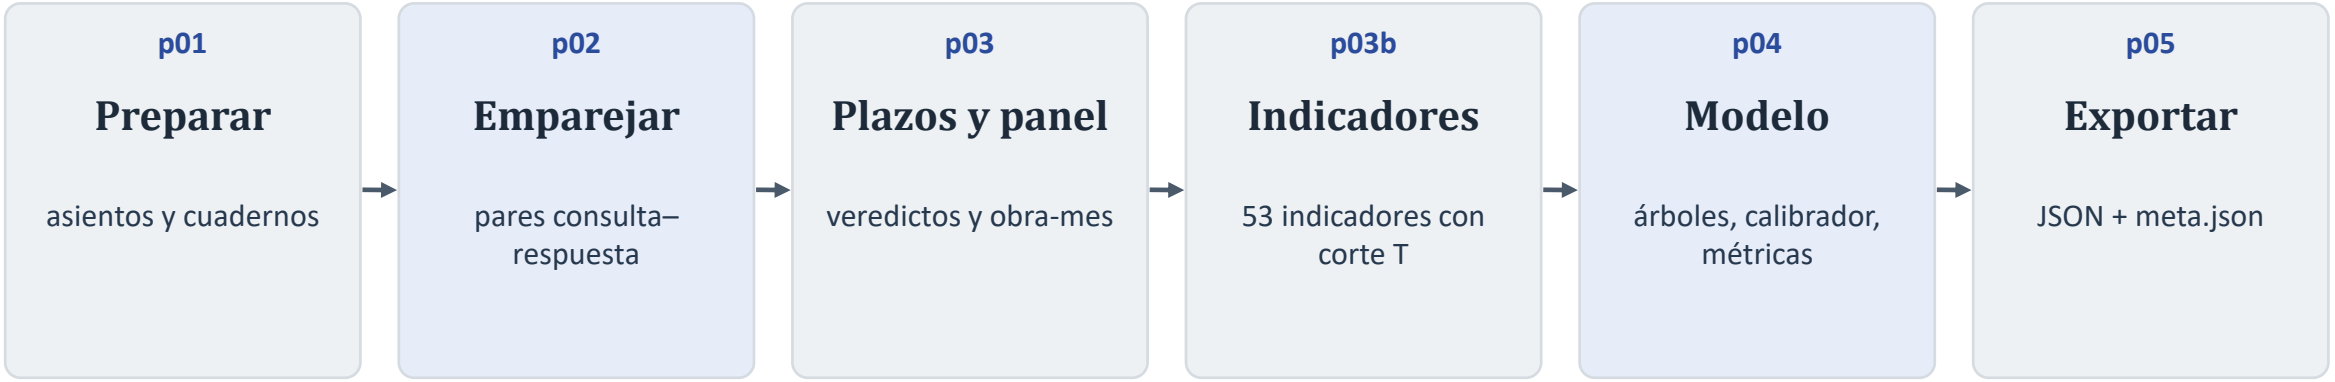
La regla que evita «ver el futuro»



Cada fin de mes T se toma una foto de la obra con lo escrito hasta T. Lo que pase después solo sirve para saber si se atrasó.

Unidad de análisis: la obra en un mes (59 653 obras-mes de 12 523 obras). **Etiqueta:** 1 si en los 60 días siguientes se anota «valorización menor al 80 %» o «calendario acelerado».

El backend es un pipeline reproducible, no un servidor



1 Reproducible

Semilla fija, orden determinista en cada consulta a datos y resultados guardados como JSON versionado en git.

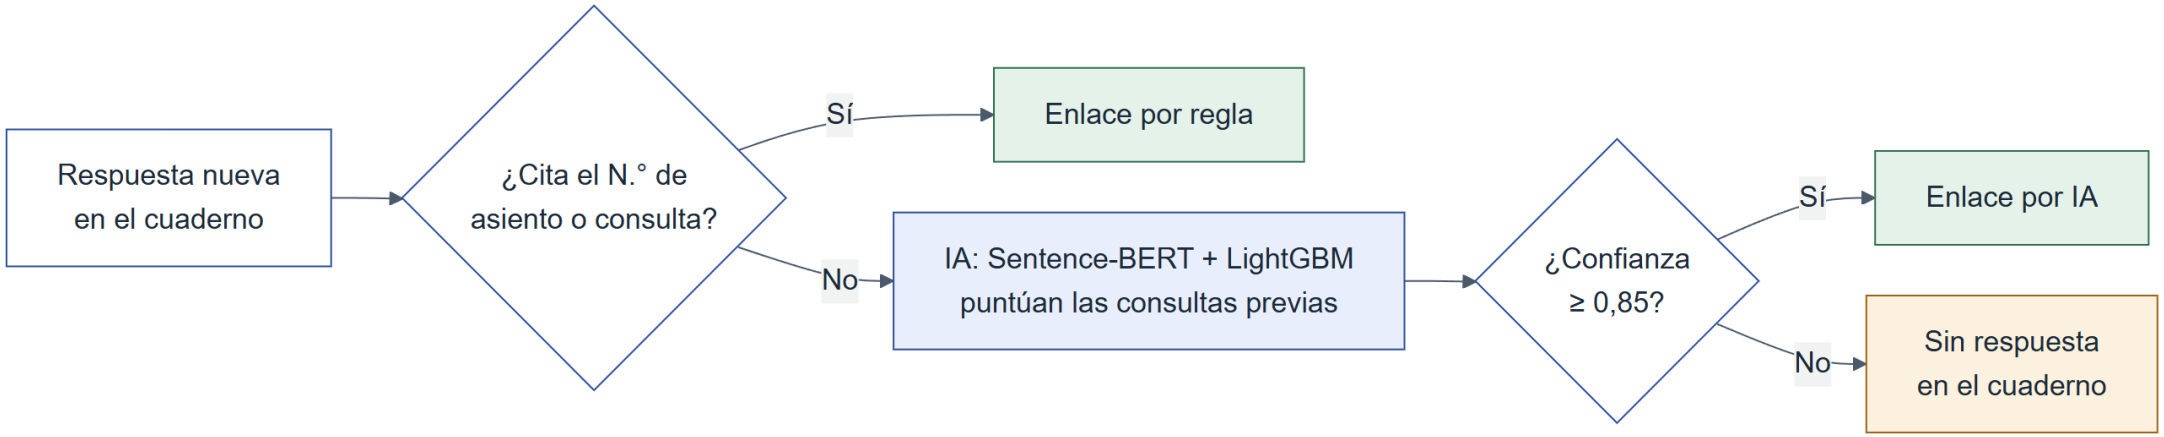
2 Puerta de calidad

p05 no publica si una probabilidad sale de [0, 1], si un nivel no cuadra con su umbral, si falta una ficha o si queda un nombre sin anonimizar.

3 Trazable

Cada corte publica la huella del modelo (fbb516a5f197c216), la del calibrador y el commit del código que lo generó.

Componente 1: unir cada respuesta con su consulta



66,8 %

acierto de la IA en 1 272 respuestas de Arequipa

52,0 %

regla «la consulta más reciente» (comparador)

Cómo lo evaluamos sin etiquetar a mano:
usamos las respuestas que sí citan el número de asiento; esa cita es la respuesta correcta. Borramos el número y pedimos al sistema que adivine. Se entrena con el resto del país y se prueba en Arequipa.

Solo se acepta un enlace de IA con confianza ≥ 0,85: 91,3 % de precisión.

Componente 2: el motor de plazos aplica la ley, no una opinión



Ruta	Plazo	Base legal	Arequipa: a tiempo / tarde / sin respuesta
Supervisor o inspector	5 días calendario	RLCE art. 193.3	1 270 / 349 / 4 025
Entidad y proyectista	21 días calendario	RLCE 193.5–193.8 · RLGCP 190	667 / 106 / 0

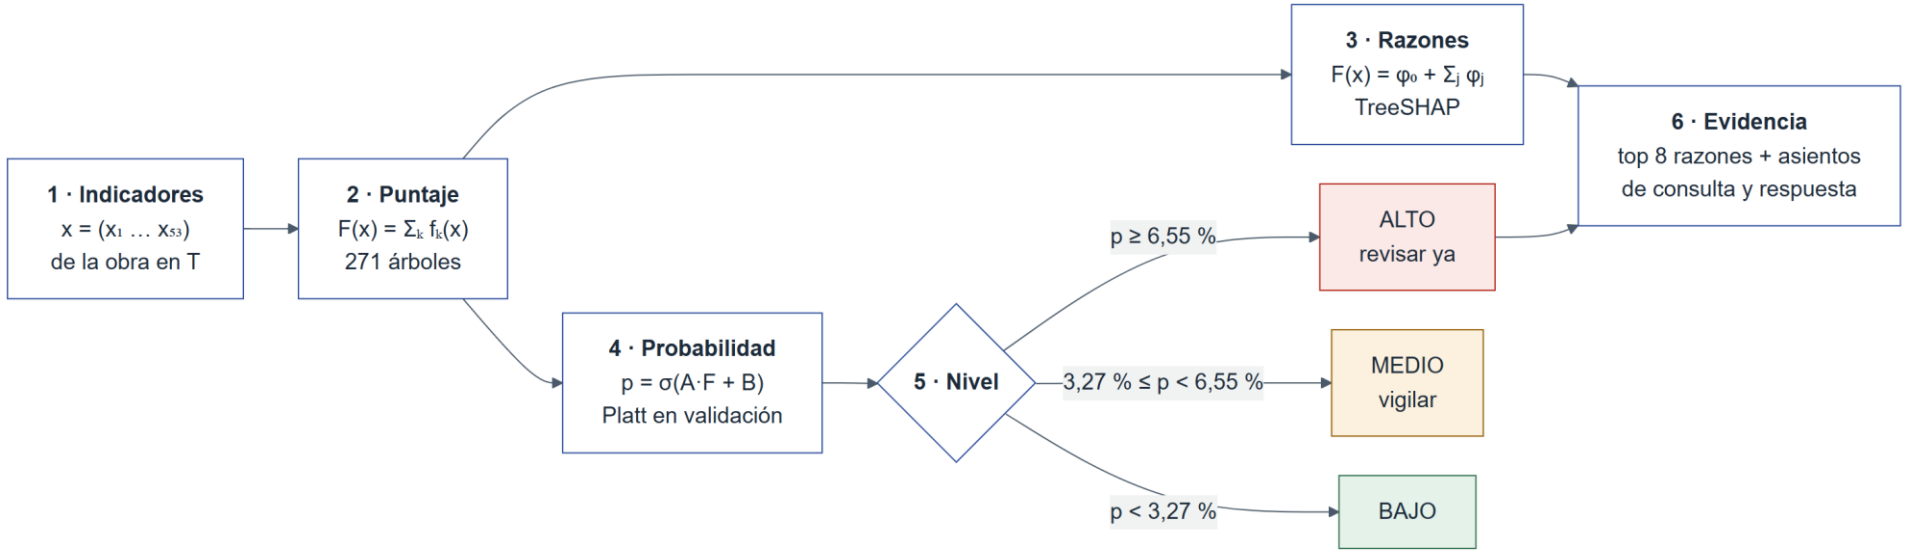
Lenguaje cuidadoso: decimos «sin respuesta en el cuaderno», no «no respondida», porque la respuesta pudo enviarse por carta.

Componente 3: 53 indicadores en 8 grupos por obra y mes

Grupo	Qué mide (ejemplos)	Fuente	Peso	Aporte*
Actividad del cuaderno	asientos 30/90 días, días sin anotar, % del supervisor, ritmo	Cuaderno	23,1 %	+0,0073
Contrato y entidad	monto contratado y viable, consorcio, nivel, sector	SEACE, MEF	17,7 %	+0,0051
Plazo y avance físico	plazo consumido frente a avance físico, días restantes	INFOBRAS + texto	16,6 %	+0,0022
Señales formales del cuaderno	ampliaciones previas, suspensiones, penalidades, órdenes	Cuaderno	13,3 %	+0,0110
Consultas y plazos legales	vencidas, en plazo, respondidas tarde, persistencia	Cuaderno + IA	10,5 %	+0,0029
Ejecución financiera	devengado SIAF / viable, meses sin pago	MEF SIAF	9,8 %	+0,0028
Historial de entidad y contratista	atrasos previos de la entidad y del contratista	Cuadernos previos	6,6 %	+0,0031
Calendario y clima	temporada de lluvias, cierre fiscal, mes	Fecha	2,4 %	+0,0018

Peso: % de la ganancia de los árboles. *Aporte: cuánto cae la PR-AUC de validación al reentrenar sin el grupo (los 8 ayudan). Fórmula, fuente y cobertura de cada indicador: Anexo D del informe.

Componente 4: cómo predice, en cuatro fórmulas



Puntaje

$$F(x) = \Sigma_k f_k(x),\ K = 271$$

Suma de árboles LightGBM sobre los 53 indicadores; la parada temprana fija K.

Probabilidad

$$p = 1 / (1 + e^{-(A \cdot F + B)})$$

Platt: A = 1,123, B = 0,107, ajustados en validación.

Nivel

$$\text{ALTO si } p \geq 6{,}55\ \%$$

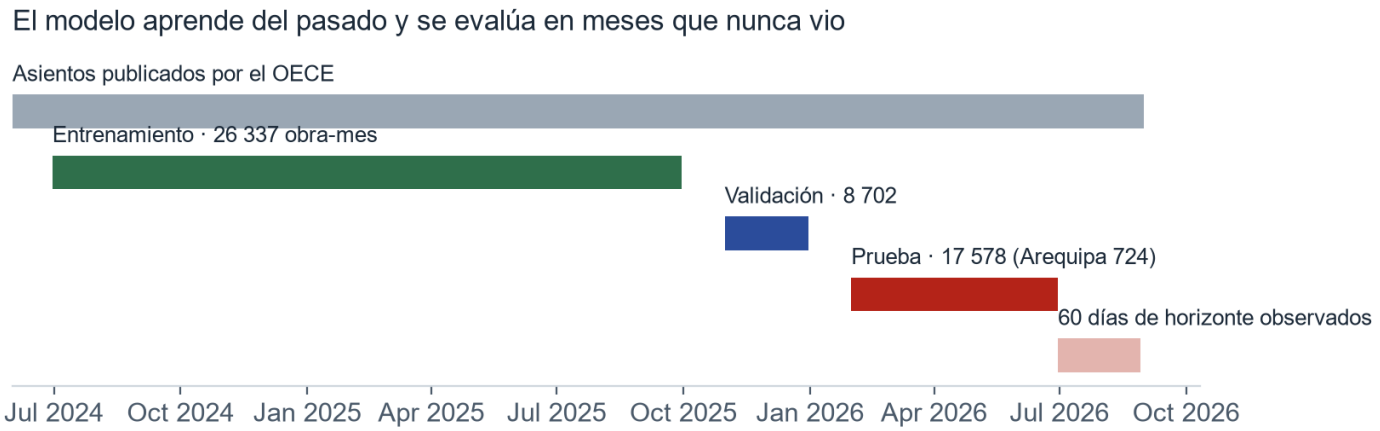
MEDIO si p ≥ 3,27 %: 20 % y 30 % de validación.

Razones

$$F(x) = \varphi_0 + \Sigma_j \varphi_j$$

TreeSHAP: $\phi_j > 0$ sube el riesgo y $\phi_j < 0$ lo baja.

Cómo evitamos engañarnos al evaluar



Métrica	Fórmula	Por qué esa
PR-AUC (principal)	$\Sigma_n (R_n - R_{n-1}) P_n$	El atraso es raro (7,0 %)
Precisión@20 %	TP_{20} / N_{20}	Capacidad real de revisión
Lift@20 %	Precisión@20 / π	Veces mejor que el azar
Brier	$(1/N) \Sigma (p - y)^2$	¿Se puede creer la probabilidad?
IC 95 %	bootstrap por obra ×1 000	Los meses de una obra no son independientes

Lista de control

- Entrenar en el pasado, probar en meses que el modelo nunca vio.
- Cinco comparadores: azar, regla, regresión logística, solo cuaderno y cuaderno + consultas.
- Modelo final elegido por validación; la prueba se mira una sola vez.
- Bootstrap pareado para comparar modelos.
- Ablación: reentrenar sin cada grupo.
- **No usamos la exactitud: decir siempre «no se atrasa» acertaría 93,0 %.**

Qué obtuvimos

Resultados medidos fuera de tiempo, con su incertidumbre y sin esconder lo que no salió

Resultados en una vista (prueba enero–junio de 2026)

0,147

PR-AUC nacional frente a una tasa base de 4,2 %; supera a la regla, la logística y al modelo solo cuaderno

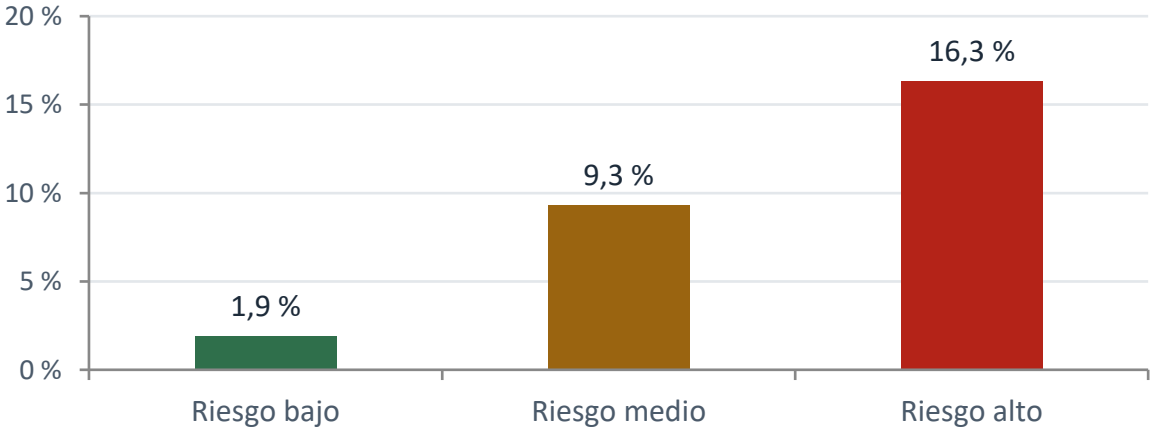
16,6 %

de las obras marcadas en Arequipa se atrasó (azar: 7,0 %): 2,3 veces más eficaz

37 días

de anticipación mediana; 65 % de las obras que se atrasaron tuvo antes alerta alta

Arequipa: obras-mes que se atrasaron, según el nivel asignado

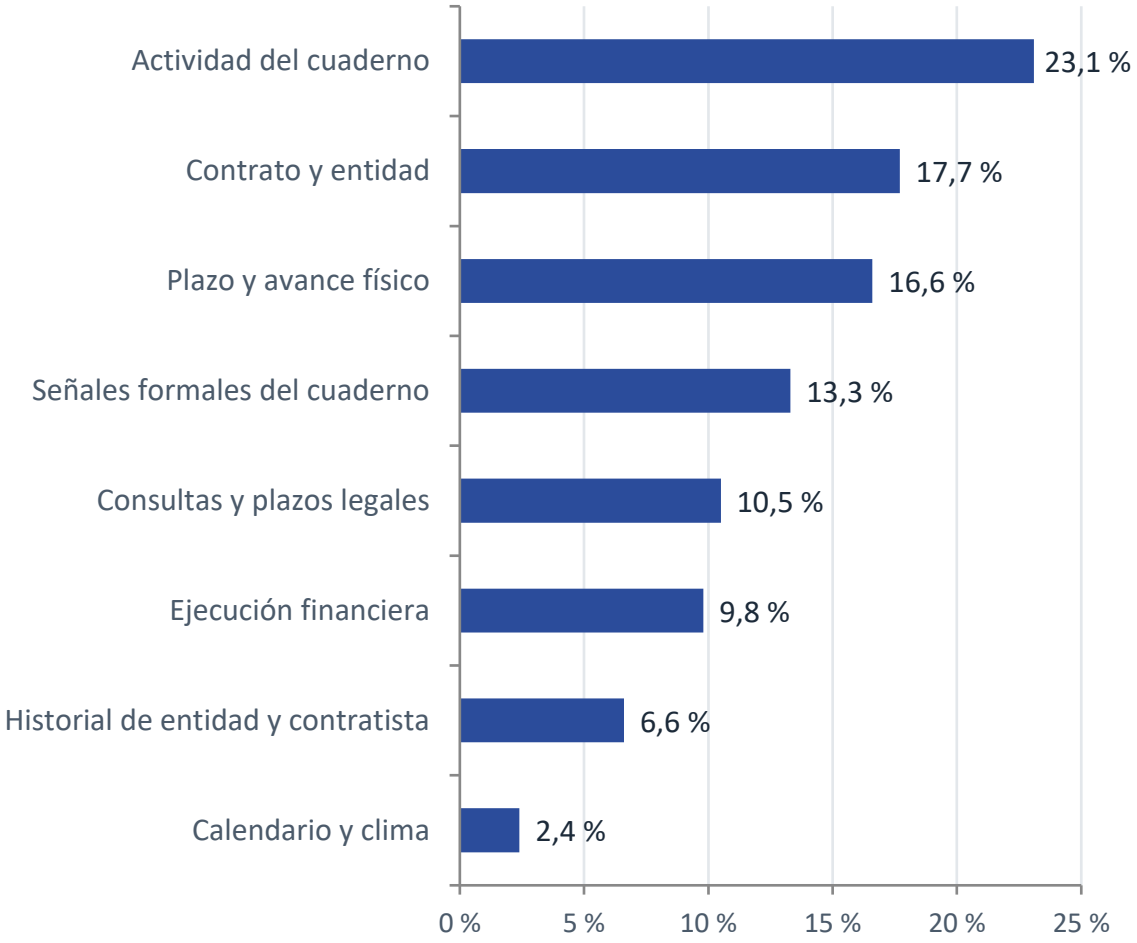


Lo que no salió tan bien (y lo decimos)

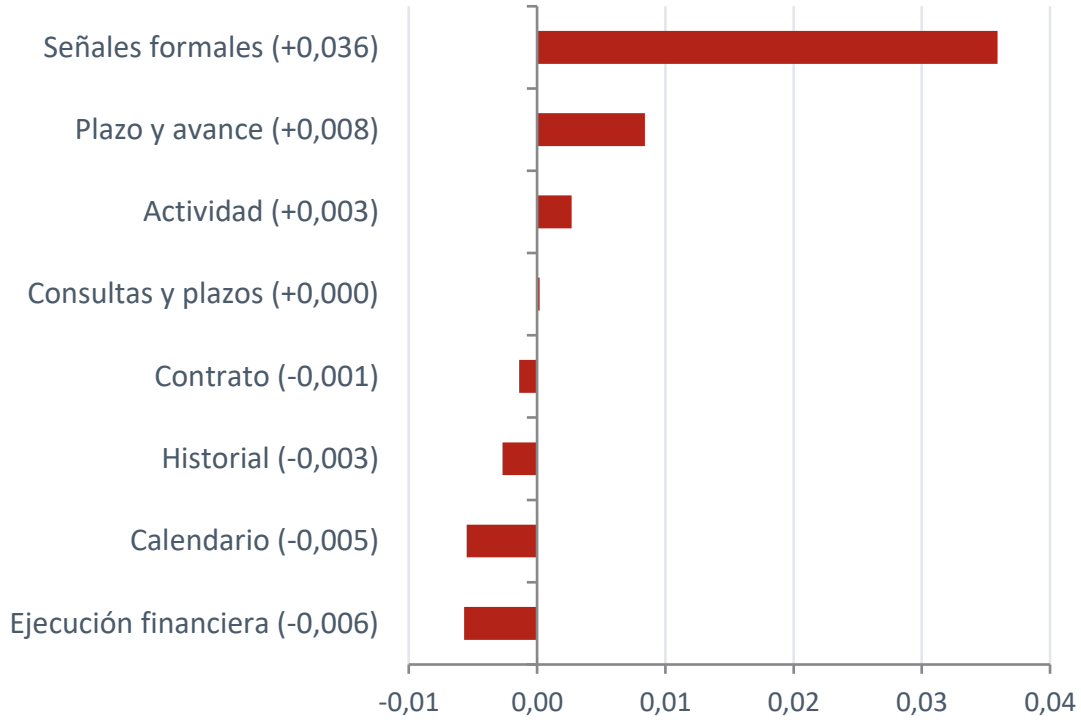
En Arequipa (51 atrasos) solo la ventaja frente al azar es concluyente; el modelo cuaderno + consultas obtuvo una PR-AUC algo mayor (0,205 frente a 0,157). Mantuvimos el modelo elegido en validación: cambiarlo mirando la prueba sería hacer trampa.

Qué usa el modelo y qué aporta de verdad cada grupo

Peso de cada grupo en el modelo (gain)

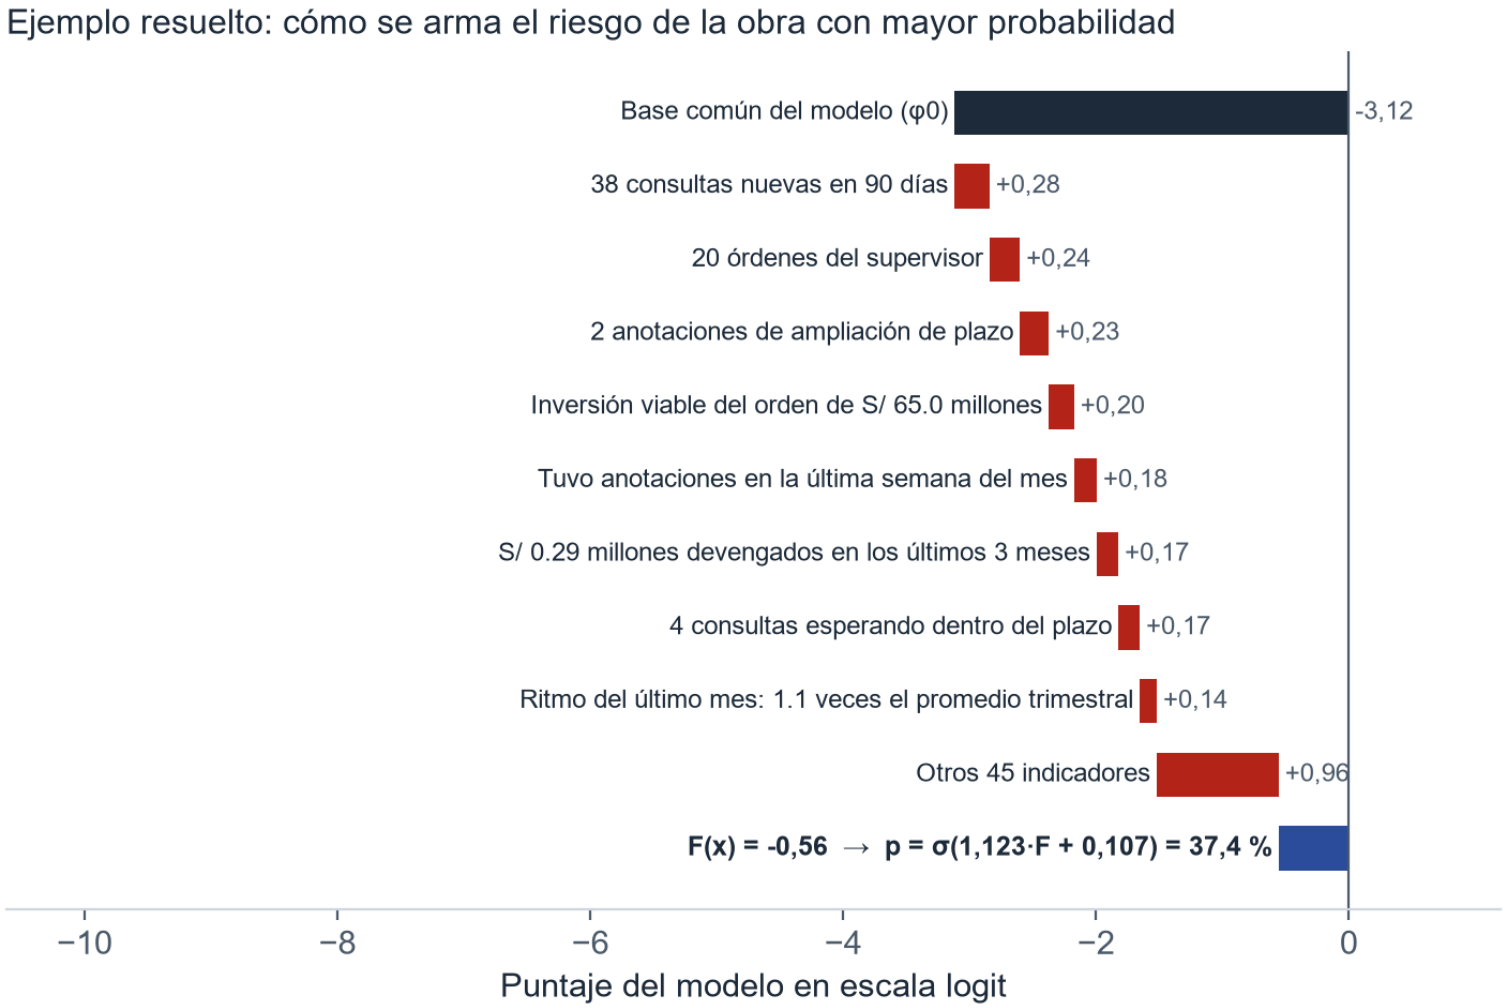


Ablación: cuánto cae la PR-AUC nacional sin el grupo



Peso no es aporte: el contrato pesa mucho pero, si se quita, otros grupos cubren su información. Lo que más mejora la predicción del país son las señales formales y el plazo frente al avance.

Ejemplo resuelto: por qué una obra tiene 37,4 % de riesgo



EJECUCION DE LA OBRA DEL SALDO DE OBRA DEL PROYECTO: AMPLIACION DE LA CAPACIDAD DE ALBERGUE Y CONSTRUCCION …
MINISTERIO DE JUSTICIA Y DERECHOS HUMANOS · SOCABAYA

Se parte de la base ϕ_0 = -3,12, se suman las contribuciones y se aplica Platt: p = 37,4 %, nivel ALTO, 5,3 veces la tasa base.

Es la misma cuenta que hace la web: cada alerta se puede auditar.

Del modelo a la pantalla

Cómo se conecta el ML con la interfaz, cómo aseguramos la calidad y cómo nos organizamos

Del modelo a la pantalla: un contrato de datos versionado

1 **modelo + calibrador**
salidas de p04

→

2 **p05 · puerta de calidad**
valida y anonimiza

→

3 **JSON + meta.json**
esquema 1 · huella

→

4 **Web modular**
verifica el esquema



Tres vistas, un propósito cada una

Panorama: qué obras revisar primero.
Ficha: riesgo, evolución, razones, consultas y el asiento como prueba.
Cómo funciona: en palabras simples para todos y, para especialistas, fórmulas, métricas y catálogo.
Para todos: recorrido guiado en cada pantalla, leyenda y globos «?».

Código: módulos ES sin dependencias (datos, formato, gráficos, vistas), enrutador por hash, CSP estricta y todo texto escapado.

El pie de página muestra el corte, la huella del modelo fbb516a5f197c216 y el commit.

Calidad de ingeniería medida, no prometida

114

pruebas automáticas en verde, también en GitHub Actions

0

violaciones WCAG 2 AA (axe-core) en las 3 vistas

566 ms

hasta ver la lista de obras (mediana de 5 cargas)

0

errores de consola; ningún dato personal publicado

Qué se prueba	Cómo	Por qué importa
Reglas de texto y anonimización	Casos de citas, DNI, CIP, correos y nombres	Un enlace o un nombre mal leído rompe la confianza
Catálogo de indicadores	53 indicadores con fórmula, fuente y frase válidas	El modelo, la web y el informe dicen lo mismo
Contrato pipeline → web	Esquema, una ficha por obra, niveles coherentes	La web nunca muestra datos mezclados
Recorrido en navegador	Escritorio y móvil, filtros, orden, rutas inválidas	Lo que ve el usuario funciona de verdad

Cómo nos organizamos: roles e hitos

1 — Datos e ingesta

Fuentes, linaje, depuración y regla del corte temporal (p01, p03b).

2 — IA y modelo

Emparejador, indicadores, entrenamiento, validación y explicación (p02, p04).

3 — Backend del pipeline

Motor de plazos, exportación, contrato de datos y puerta de calidad (p03, p05).

4 — Frontend

Vistas, accesibilidad, rendimiento y seguridad de la web.

5 — Calidad y gestión

Pruebas, CI, informe GESITI, diapositivas y control de cambios.

H1	Problema y datos verificados	logrado
H2	Emparejador y motor de plazos	logrado
H3	Indicadores y modelo validado	logrado
H4	Web publicada con contrato y pruebas	logrado
H5	Informe y sustentación	logrado
H6	**Prueba con supervisores (SUS)**	pendiente

Riesgos que anticipamos y cómo los controlamos

Riesgo	Qué pasaría	Control que ya está implementado
Fuga de información temporal	Métricas infladas que fallan en la realidad	Corte T en cada indicador; prueba temporal
Enlace consulta–respuesta equivocado	Veredicto de plazo falso	Umbral de confianza 0,85 (91,3 % de precisión)
Uso de la alerta como acusación	Daño a personas o empresas	Se presenta como prioridad de revisión, con su prueba
Datos personales en los asientos	Incumplir la Ley 29733	Anonimización + prueba + puerta de calidad
Pocos casos en Arequipa	Conclusiones locales frágiles	Entrenar con el país; intervalos por obra
Cambio de formato del OECE o deriva	Datos mezclados o modelo desactualizado	Contrato con esquema; recalibrar y revisar tasas por nivel en cada corte

Límites y siguientes pasos

Límites que declaramos

Predice el atraso legal (menos del 80 % de lo programado), no la paralización.

Solo obras por contrata con cuaderno digital, desde junio de 2024.

No ve las respuestas enviadas por carta.

El avance físico y el monto tienen poca cobertura en las fuentes.

Siguientes pasos

Prueba de uso (SUS) con supervisores y Órganos de Control de Arequipa.

Pedir al OECE que publique el identificador de asiento para validar los enlaces.

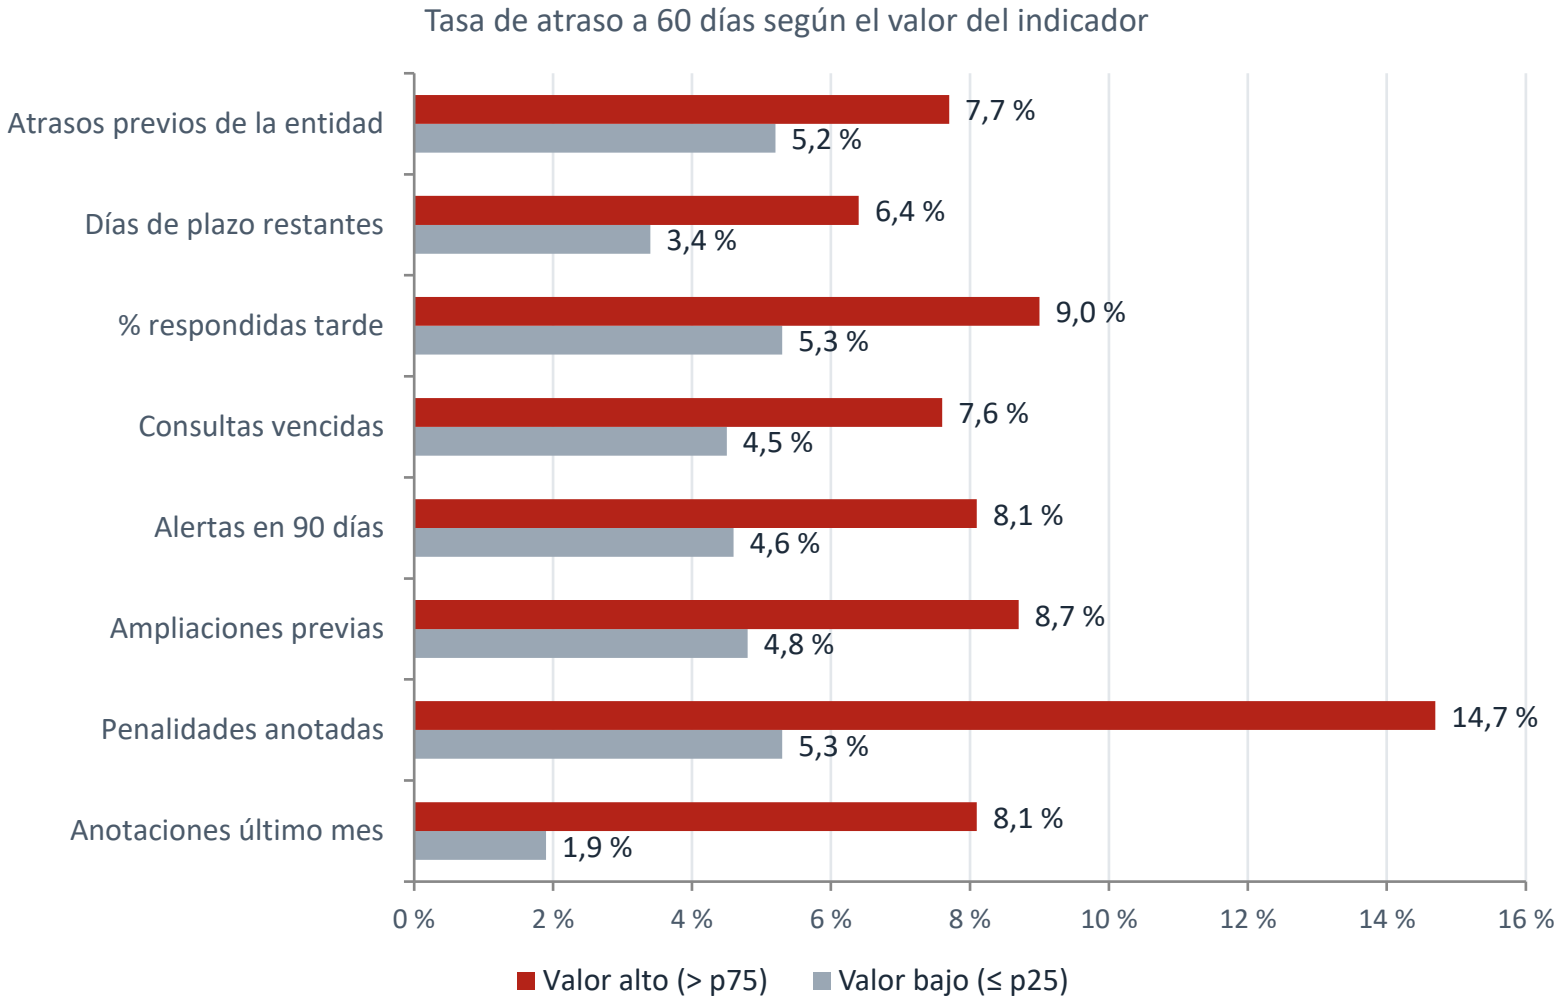
Predecir también la ampliación de plazo por consultas sin absolver.

Actualización mensual automática y extensión a otras regiones.

Lo que demostramos

1. Con datos abiertos e IA se reconstruye lo que el Estado no publica: qué respuesta contesta qué consulta (66,8 % de acierto).
2. Las respuestas son poco trazables: solo 37 % queda en el cuaderno y 19 % llega tarde.
3. Leer el cuaderno y cruzarlo con plazo, dinero e historial anticipa el atraso: PR-AUC 0,147 (base 4,2 %) y 37 días de aviso.
4. Todo con decisiones justificadas, pruebas automáticas, costo cero y cada alerta explicada con su prueba escrita.

Anexo A · Patrones en los datos de entrenamiento



35 039 obras-mes de entrenamiento y validación; tasa base 5,6 %. La prueba no se miró.

Penalidades anotadas: 2,8 veces más riesgo.
Consultas vencidas: 1,7 veces.
Obra con mucha actividad: 4,3 veces.

Son asociaciones, no causas: el modelo combina todos los indicadores.

Anexo B · Resultados completos de la prueba

Modelo	PR-AUC Arequipa [IC 95 %]	Precisión@20 AQP	PR-AUC nacional [IC 95 %]	p (M mejor) nacional
B0 Azar (tasa base)	0,070 [0,048–0,098]	6,9 %	0,042 [0,038–0,046]	< 0,001
B1 Regla: consultas vencidas	0,123 [0,060–0,227]	6,9 %	0,059 [0,049–0,072]	< 0,001
B2 Regresión logística	0,163 [0,100–0,269]	15,9 %	0,119 [0,101–0,145]	0,001
B3 LightGBM solo cuaderno	0,186 [0,104–0,316]	13,8 %	0,129 [0,109–0,153]	0,015
M1 Cuaderno + consultas	0,205 [0,128–0,377]	17,2 %	0,137 [0,118–0,162]	0,098
M Caja Negra (8 grupos)	**0,157 [0,102–0,252]**	**16,6 %**	**0,147 [0,125–0,175]**	**—**

Prueba: Arequipa 724 obras-mes y 51 atrasos; país 17 578 obras-mes y 734 atrasos. Valor p: bootstrap pareado por obra, 1 000 remuestreos. Selección por PR-AUC de validación: B3 0,104 · M1 0,106 · M 0,113.